

İleri Beslemeli Sinir Ağları ile Türk Üst Mahkemelerinde Karar Tahmini

Feedforward Neural Network Based Case Prediction in Turkish Higher Courts

Arda C. ARAS

Elektrik ve Elektronik Mühendisliği Bölümü
Ulusal Manyetik Rezonans Araştırma Merkezi (UMRAM)
Bilkent Üniversitesi
Ankara, Türkiye
can.aras@bilkent.edu.tr

Ceyhan E. ÖZTÜRK

Elektrik ve Elektronik Mühendisliği Bölümü
Bilkent Üniversitesi
ASELSAN Research Center
Ankara, Türkiye
ceyhun.ozturk@bilkent.edu.tr

Aykut KOÇ

Elektrik ve Elektronik Mühendisliği Bölümü
Ulusal Manyetik Rezonans Araştırma Merkezi (UMRAM)
Bilkent Üniversitesi
Ankara, Türkiye
aykut.koc@bilkent.edu.tr

Özetçe —Doğal dil işleme (DDİ) yöntemleri sayesinde hukuki metinler bilgisayarlar tarafından işlenip, hukuk alanında karar tahmin uygulamaları geliştirilebilmektedir. Türk Hukuk sistemindeki açık veri kaynaklarının da her geçen gün artması, bu alan için yeni uygulamalar geliştirilmesine fırsat sunmaktadır. DDİ uygulamaların geliştirilebilmesi için gerekli derlemlere ulaşılmıştır. Bu çalışmada Türk üst mahkemelerinin sitelerinde kamu erişimine açık yayımlanan ve kişisel bilgilerden arındırılmış dava metinleri karar tahmin yöntemlerinin geliştirilmesi için kullanılmıştır. Derlem elde edildikten sonra İleri Beslemeli Sinir Ağları (FFNN), kelime temsilleri ve metinlerden Temel Bileşenler Analizi (PCA) ile çıkarılan öznetelikler kullanılarak eğitimler yapılmıştır. Karar tahmini için %85.4 Makro F1 skoruna ulaşılmıştır.

Anahtar Kelimeler—Doğal Dil İşleme, İleri Beslemeli Basit Sinir Ağları, Türkiye Yüksek Mahkemeleri

Abstract—Thanks to natural language processing (NLP) methods, legal texts can be processed by computers and decision prediction applications can be developed in the legal tech field. Increase in the available data sources in the Turkish legal system provides an opportunity to develop NLP applications as well. In order to develop these applications, the necessary corpora and datasets should be created. In this work, legal case texts from the Turkish Higher Courts that are open to public access and free from personal data are used to develop decision prediction methods. Feedforward neural networks (FFNN) are deployed using word embeddings and the features extracted from texts via the Principal Component Analysis (PCA) algorithm. %85.4 Macro F1 score level is achieved.

Keywords—Natural language processing, Feedforward neural networks, legal tech, legal NLP

I. GİRİŞ

Hukuk, sosyal, politik, ekonomik ve teknolojik değişimler karşısında toplumun güncel ve değişken ihtiyaçlarını karşılayabilmek için genişleyip evrilmektedir. Hem yasamanın sürekli değişimi hem de emsal karar sayısındaki hızlı artış hukukçuları sürekli artan bir sorumluluk altında bırakmaktadır. Bu durum, hukuk sektöründe teknoloji kullanımı ile karar destek sistemleri ve diğer algoritmik desteklerin mümkün olup olmadığının sorgulanmasına yol açmıştır. Böyle bir sistem, avukatların, savcılarının ve yargıçların işlerini kolaylaştıracaktır. Bu teknolojiler, zaman tasarrufu, hata sayısının azaltılması ve tutarlılığı arttırmaları sebebiyle kamu yararına katkıda bulunacaktır. Makinelerin devasa miktarda hukuk metinlerini çok hızlı bir şekilde tarayıp analiz edebilmesi, amaçlanan karar tahmin modelinin oluşmasına olanak sağlayacaktır.

Hukukta DDİ teknolojileri alanında, özellikle mahkeme karar tahmini üzerine daha önce yapılmış pek çok uluslararası çalışma bulunmaktadır [1]–[5]. DDİ tabanlı yapay zeka uygulamalarının hukuk alanında kullanılabileceğine dair ilk fikir Buchanan ve Hendrick tarafından 1970’te tartışılmıştır [6]. Uluslararası alanda, DDİ uygulamalarının Hukuktaki kullanımları [7]’de detaylıca incelenmiştir. DDİ uygulamalarında kelime temsilleri yaygın olarak kullanılmaktadır. Word2vec [8], GloVe [9], fastText [10] ve BERT [11] kelime temsili üretiminde kullanılan popüler algoritmalarlardır. Hukuk alanına özel kelime temsilleri için LEGAL-BERT algoritması geliştirilmiştir [12]. Buna ek olarak genel kelime temsillerinin önemli problemlerinden biri olan cinsiyetçi önyargı problemi, hukuk metinleri özelinde çalışılmıştır [13]. Hukuk özelinde olmayan Türkçe genel kelime temsilleri üzerine de çalışmalar bulunmaktadır [14], [15].

Bunun yanında Türk Hukuk sistemi için DDİ çalışmaları konusunda literatürde çok az sayıda çalışma bulunmaktadır [16]. Türk hukuk sisteminde ilk DDİ çalışması [16]'da yapılmıştır ve karar ağacı, rassal orman ve vektör destek makinesi modelleri ile derin öğrenme yöntemi olarak birer mükerrer sinir ağı (RNN) türevi olan mükerrer birimli sinir ağı (GRU) [17] ve uzun ve kısa vade hafızalı sinir ağı (LSTM) [18] modelleri de kullanılmıştır. Bu bildiride [16]'dan farklı olarak ileri beslemeli sinir ağları (FFNN) ve hukuk alanında özel kelime temsilleri kullanılarak mahkeme karar tahmini yapılmıştır.

Çalışmamız kapsamında incelenen tüm üst mahkemelerin kararları iki sınıflı olarak değerlendirilmiştir. İncelenen tüm dava metinleri üst mahkemelerin resmi internet sitelerinden indirilmiştir. Bu mahkemeler *Anayasa Mahkemesi (AYM)*, *Bölge Adliye Mahkemeleri (Hukuk ve Ceza)*, *Bölge İdare Mahkemeleri (İdari ve Vergi)* olarak beş farklı istinaf mahkemesini içermektedir. Her bir mahkeme için toplamda altı farklı girdiye sahip olan FFNN modelleri kullanılacaktır. Altı farklı modelin beşinde girdi olarak farklı kelime temsilleri kullanılırken, geriye kalan diğer model metinlerden çıkartılan özniteliklerin kullanılması ile eğitilmiştir. Modellerin detayları ve girdilerinin nasıl oluşturduğu bildirinin III. kısımda (Yöntemler) yer almaktadır.

II. VERİ SETİ HAZIRLANMASI

A. Anayasa Mahkemesi

AYM'ye yapılan 6.485 farklı bireysel başvuru bulunmaktadır. AYM kararları, davaya konu edilen anayasal haklara göre kategorize edilebilmektedir. Ancak bir davada birden fazla hakkın ihlal edildiğine ilişkin değerlendirmelerin yapılmış olması mümkündür. Bu kategorizasyon tamamlandığında, 21 tanesi 100'den az, 7 tanesi 10'dan az karar içeren toplam 41 kategori elde edilmiştir. Yer alan kategorilerin sahip olduğu dava sayılarının azlığından dolayı tüm kategoriler ile birleşik bir veri seti de ayrıca oluşturulmuştur. Tüm *ihlal var* ve *ihlal yok* kararları bir araya getirilerek karıştırılmıştır. Birden fazla hakkın ihlaline ilişkin iddiaların değerlendirildiği davalarda hem ihlalin varlığı hem de yokluğuna ilişkin birleşik kararlar da derlemden çıkarılmıştır. Böylece, 149 *ihlal yok*, 1.141 *ihlal var* şeklinde toplam 1.290 dava elde edilmiştir. Bu derleme ilişkin veriler Tablo I'de verilmiştir.

B. Bölge Adliye Mahkemeleri Hukuk Daireleri

Bölge Adliye Mahkemesi Hukuk Daireleri'ne ait erişilebilir 47.796 kararın tamamı çalışmamıza dahil edilmiştir. Karar metinleri, ilk andan itibaren 'GEREKÇE', 'KARAR', 'DEĞERLENDİRİLMESİ/DEĞERLENDİRME', 'HÜKÜM' anahtar kelimeleri ile yapılan aramalar ile bölünmüş, geriye kalan makine öğrenmesi modelinden gizli tutulmuştur. Sonuç olarak kalan dokümanlara ilişkin rakamlar Tablo I'de sunulmuştur.

C. Bölge Adliye Mahkemeleri Ceza Daireleri

Bölge Adliye Mahkemeleri Ceza Daireleri için oluşturulan derlemde toplam 9.241 karar kullanılmıştır. 'GEREĞİ DÜŞÜNÜLDÜ' haricinde bölünme işlemi için 'GEREKÇE', 'KARAR', 'DEĞERLENDİRİLMESİ/DEĞERLENDİRME', 'HÜKÜM' anahtar kelimeleri kullanılmıştır. Etiketleme kısmında ise yukarıdakilere ek olarak 'YER OLMADIĞINA' kavramını

bulunduran kararlar da 'RED' sayılmıştır. Bölünemeyen kararlar ve karışık kararlar da çalışmadan ayrılmıştır. Sonuç olarak kalan dokümanlara ilişkin rakamlar Tablo I'de sunulmuştur.

D. Bölge İdare Mahkemeleri İdare Daireleri

Bölge İdare Mahkemeleri İdare Daireleri için oluşturulan derlemde toplam 20.948 karar kullanılmıştır. Bu kararlar farklı şekli özelliklere sahiptir. Olay özeti ile başlayıp 'TÜRK MİLLETİ ADINA' başlığundan sonra muhakeme ve karar kısımlarından oluşmaktadır. Bu kararların bahsedilen başlıktan itibaren bölünmüş önceki olay özeti kısımları modelin eğitilmesi için kullanılmıştır. Etiketleme işlemi için ise yukarıda bahsi geçen anahtar kelimeler kullanılmıştır. Bölünemeyen kararlar ve karışık kararlar da çalışmadan ayrılmıştır. Sonuç olarak kalan dokümanlara ilişkin rakamlar Tablo I'de sunulmuştur.

E. Bölge İdare Mahkemeleri Vergi Daireleri

Bölge İdare Mahkemeleri Vergi Dairelerine ait 8.870 karar çalışmaya dahil edilmiştir. Bölünme ve etiketleme işlemleri İdare Daireleri ile aynı şekilde gerçekleştirilmiştir. Sonuç olarak kalan dokümanlara ilişkin rakamlar Tablo I'de sunulmuştur. Her bir mahkeme için kararlar üzerinde yukarıda açıklanan işlemler gerçekleştirildikten sonra elde edilen derlem eğitim, doğrulama ve test bölümlerine ayrılmıştır. Derlem için eğitim, doğrulama ve test setleri oranları %75-%15-%15 şeklindedir.


Mahkeme Adı	İndirilen Dava Sayısı	Tasniflen Dava Sayısı
AYM	6.485	1.290
Bölge Adliye Mahkemeleri Hukuk Daireleri	47.796	26.327
Bölge Adliye Mahkemeleri Ceza Daireleri	9.241	4.385
Bölge İdare Mahkemeleri İdari Daireleri	20.948	19.046
Bölge İdare Mahkemeleri Vergi Daireleri	8.870	8.302

TABLO I: İndirilen ve Tasniflenen Davaların Sayısı.

III. YÖNTEMLER

Kullanılan tüm yöntemlerin FFNN mimari yapısı aynıdır fakat girdi olarak farklılıklar içermektedir. FFNN yapısı olarak [19]'den esinlenilmiştir. Kullanılan mimaride 2 gizli katman ve 1 softmax katmanı kullanılmıştır. İlk gizli katmanda 50, ikinci gizli katmanda ise 10 nöron kullanılmıştır. Modelin mimarisi Şekil 1'de sunulmuştur. Dava metinlerinde yer alan kelimelerin, kelime temsillerinin ortalaması modele girdi olarak verilmiştir. Temel Bileşenler Analizinde ise dava metni için bir vektörel gösterim oluşturulmuş ve bu vektör girdi olarak modele verilmiştir. Bu girdilerin nasıl oluşturulduğu aşağıdaki alt başlıkta detayları ile birlikte anlatılmaktadır. Mahkemelerdeki davaların sınıfsal dağılımının eşit olmaması sorunu, kayıp fonksiyonunun ağırlıklı olarak eğitilmesi ile çözülmesi hedeflenmiştir. Aşağıda tanımlanan Doğruluk, Makro Yakalama, Makro Kesinlik ve Makro F1 Oranları başarımleri metrikleri olarak kullanılmıştır: Doğruluk Oranı, Makro Yakalama Oranı ve Makro Kesinlik Oranı sırasıyla; $(TP + TN) / (TP + TN + FP + FN)$, $TP / (TP + FN)$ ve $TP / (TP + FP)$ değerlerine sahip olmaktadır.

$$\text{Makro F1 Oranı} = \frac{2 \cdot \text{Kesinlik} \cdot \text{Yakalama}}{\text{Kesinlik} + \text{Yakalama}} \quad (1)$$



Şekil 1: FFNN Mimari Yapısı. N, bir dava metninde bulunan toplam kelime sayısını göstermektedir.

Yukarıdaki tanımlarda, TP, TN, FP ve FN sırasıyla gerçek pozitif, gerçek negatif, yanlış pozitif ve yanlış negatif örnek sayılarıdır.

Mahkeme Adı	Sözlük Boyutu	PCA Boyutu
AYM	10.606	334
Bölge Adliye Mahkemeleri Hukuk Daireleri	12.946	587
Bölge Adliye Mahkemeleri Ceza Daireleri	6.041	119
Bölge İdare Mahkemeleri İdari Daireleri	8.123	607
Bölge İdare Mahkemeleri Vergi Daireleri	4.795	250

TABLO II: Vektör Boyutlarının PCA Uygulanmadan ve Uygulandıktan Sonraki Hali

A. Wikipedia Kelime Temsilleri

2021 Türkçe Wikipedia makaleleri ve word2vec algoritması kullanılarak eğitilmiş Turkish-word2vec kelime temsilleri kullanılmıştır [14]. Kullanılan kelime vektörü kümesinde 412.457 kelime (token) bulunmaktadır. Kelime temsilleri 400 boyutludur.

B. lawTurk2Vec 100 Boyutlu Kelime Temsilleri

Çalışmamız kapsamında Türkçe hukuk metinleri için özel-leştirilmiş *LawTurk2Vec* kelime temsilleri eğitilmiştir. Bu temsillerin oluşturulmasında [20]'de yer alan İngilizce hukuki metinler kullanılarak üretilen law2Vec yaklaşımından ilham alınmıştır. Algoritmada girdi olarak Bölüm II'de detayları verilen Türk yüksek mahkemelerinin derlemi kullanılmıştır. Bu kelime temsillerinde her biri 100 boyutlu 169.736 kelime vektörü bulunmaktadır.

C. lawTurk2Vec 300 Boyutlu Kelime Temsilleri

Bir önceki alt başlıkta bahsedilen tekniğin aynısı kullanılmıştır. Kelime temsilleri 100 boyutlu bir uzay yerine 300 boyutlu bir uzayda eğitilmiştir.

D. word2vec+law_tr Kelime Temsilleri

Bu kelime temsilleri Bölüm 3.A'da verilen Türkçe Wikipedia kelime temsillerinden başlayarak, Türkçe hukuk metinleri derlemi kullanılarak tekrar eğitilmeleri ile üretilmiştir. Wikipedia kelime temsilleri gibi word2vec+law_tr kelime temsilleri de 400 boyutludur. Küme toplamda 446.153 kelimeden oluşmaktadır. Tekrar eğitim için [21]'de yer alan SOWE algoritması kullanılmıştır. Bu algoritma ile kelime eğitilen kelime temsili kümesi içindeki vektörler güncellenmiştir. Ayrıca, tekrar eğitim için kullanılan derlemden bulunan yeni kelimeler de tekrar eğitilen kelime temsili kümesine eklenir.

E. w2v_law2v_merged_tr Kelime Temsilleri

Bu küme Wikipedia kelime vektörleri ve 100 elemanlı lawTurk2Vec vektörleri uçuca ekleme (concatenation) kullanılarak oluşturulmuştur. Wikipedia ve lawTurk2Vec kelime

AYM	Doğruluk	Yakalama	F1	Kesinlik
PCA	78,1	56,8	56,1	55,7
Wikipedia	80,7	52,5	51,5	51,6
lawTurk2Vec 100dim	75,5	58,2	52,9	53,6
lawTurk2Vec 300dim	64,5	63,6	49,8	54,4
wordVec + law_tr	81,2	52,8	51,8	51,8
w2v_law2v_merged_tr	86,9	55,9	56,1	56,3

Hukuk Daireleri	Doğruluk	Yakalama	F1	Kesinlik
PCA	63,3	62,2	62,2	62,1
Wikipedia	55,9	54,1	54,1	54,2
lawTurk2Vec 100dim	55,3	53,9	53,9	53,9
lawTurk2Vec 300dim	55,4	54,6	54,5	54,5
wordVec + law_tr	55,3	54,1	54,1	54,1
w2v_law2v_merged_tr	55,4	53,5	53,5	53,5

Ceza Daireleri	Doğruluk	Yakalama	F1	Kesinlik
PCA	77,8	74,5	69,5	67,8
Wikipedia	80,3	65,9	67,4	70,4
lawTurk2Vec 100dim	74,0	62,9	62,2	61,7
lawTurk2Vec 300dim	67,1	56,2	55,3	55,1
wordVec + law_tr	78,4	58,4	59,4	64,6
w2v_law2v_merged_tr	78,2	61,5	62,6	65,2

İdari Daireleri	Doğruluk	Yakalama	F1	Kesinlik
PCA	87,3	72,9	72,7	72,5
Wikipedia	84,2	59,5	60,3	61,5
lawTurk2Vec 100 dim	81,9	59,2	58,9	58,7
lawTurk2Vec 300dim	72,2	56,2	53,2	53,6
wordVec + law_tr	74,8	61,9	57,4	57,1
w2v_law2v_merged_tr	84,1	57,9	58,8	60,4

Vergi Daireleri	Doğruluk	Yakalama	F1	Kesinlik
PCA	91,8	88,7	85,0	82,3
Wikipedia	86,3	70,3	72,1	74,6
lawTurk2Vec 100dim	84,7	69,8	70,5	71,3
lawTurk2Vec 300dim	81,8	70,2	68,6	67,4
wordVec + law_tr	78,2	67,2	64,6	63,3
w2v_law2v_merged_tr	86,1	68,4	70,7	74,4

TABLO III: Çeşitli üst mahkemeler ve önerilen metodlar için deneysel sonuçlar. Değerler % olarak verilmiştir.

temsillerinin her ikisinde de bulunan kelimelerin bu iki kümedeki vektörleri art arda eklenerek 500 elemanlı yeni vektörler oluşturulmuştur. Oluşan kümede toplamda 123.573 kelime bulunmaktadır.

F. Temel Bileşen Analizi (PCA)

Dava metni bazında öznitelik vektörleri oluşturmak için, öncelikle tüm metin üzerinde *Zemberek* kullanılarak kelime kökleri çıkarılmıştır [22]. Bu kök bulma metodu, Türkçe gibi sondan eklemeli diller için de uygun olan [23] gibi çalışmalardan farklı olarak el ile girilen bir algoritma ile gerçekleştirilmiştir. Sayılar, tarihler vb. kelimelerin atılmasıyla birlikte yalnızca anlamsal metin kalmıştır. Bu kelimelerden bir sözlük yaratılır ve derlem içerisindeki oluşum sayısı 50 eşliğinin altında kalan nadir sözcükler çıkarılmıştır. Böylece, bu eşğin altında kalan sözcükler genelde uygun kelimeler olmuştur. Her bir kelimeye dair sözlükteki karşılığı olarak kelime sıklıklarına karşılık ve kelime oluşum sayısına karşılık bir vektör oluşturulmuştur. Her bir derlem için sözlük büyüklükleri Tablo II' de görülmektedir. Vektör uzayının boyut sayısını azaltmak amacıyla, PCA uygulanmıştır. PCA boyutları her mahkemedeki verilerin %95'i korunacak şekilde seçilmiştir. Böylece, önemli derecede boyut azaltılması sağlanmıştır. Tablo II, orijinal sözlük ve PCA uygulandıktan sonraki sonuçları birlikte göstermektedir.

IV. DENEYLER VE SONUÇLAR

Önerdiğimiz çeşitli metotların test kümesi üzerindeki performansı Tablo III'te her bir model için yer almaktadır. Model kıyaslaması yapılırken F1 skoru kriter olarak belirlenmiştir ve en iyi F1 skoru tabloda koyu renk ile belirtilmiştir. Veri setindeki dengesizlik sebebiyle sınıflandırma problemlerinde az örneği bulunan sınıflardaki örneklerin doğru etiketlenmesine ağırlık veren makro yakalama ve makro F1 gibi performans metrikleri önem kazanmaktadır. Bu performans ölçütlerini asıl kriter olarak belirlemek yaptığımız deneyin sonucunun doğruluğunu daha net şekilde yansıtmaktadır.

Çalışma	Mahkeme Adı	Girdi	Doğruluk	Makro F1
[16]	Anayasa Mahkemesi	PCA Wikipedia	77 86,6	47,5 50
[16]	Bölge Adliye Mahkemeleri Hukuk Daireleri	PCA Wikipedia	52,4 67,6	50,9 66,5
[16]	Bölge Adliye Mahkemeleri Ceza Daireleri	PCA Wikipedia	72,3 82,3	48,9 74,2
[16]	Bölge İdare Mahkemeleri İdari Daireleri	PCA Wikipedia	77,7 89,8	49,7 76,6
[16]	Bölge İdare Mahkemeleri Vergi Daireleri	PCA Wikipedia	85,4 90,3	71,9 82,8

TABLO IV: Wikipedia kelime temsilleri ve PCA girdileri ile karar tahmini. Değerler % olarak verilmiştir.

[16]'da ulaşılmış performanslar, bu bildiride sunulan metotlarla kıyaslayabilmek için Tablo IV'te ayrıca verilmiştir. Bu bildiride hem wikipedia kelime temsilleri hem de PCA algoritması ile çıkarılan öznetelikler bulunduğu için [16]'da yer alan hem geleneksek algoritmalarla hem de derin öğrenme algoritmalarıyla kıyaslanma yapılmıştır.

V. SONUÇ

Yapılan çalışmada [16]'da yer alan metotların üzerine yeni metotlar geliştirilmiştir. Yapılan deneyler sonucunda, Tablo III'e bakıldığında her üst mahkemede en iyi sonucu PCA ile elde edilen vektör girdileri ile oluşan modeller sağlamıştır. Elde edilen sonuçlar Tablo IV ile kıyaslandığında PCA girdisi olarak tüm mahkemelerde [16]'da yer alan sonuçlardan daha iyi sonuç elde edilmiştir. AYM için Wikipedia kelime temsillerinin girdi olarak kullanıldığı modeller kıyaslandığında, bu bildiride yer alan FFNN modeli ile daha iyi sonuç elde etmiştir.

BİLGİLENDİRME

Bu çalışma Türkiye Bilimsel ve Teknolojik Araştırma Kurumu (TÜBİTAK) (1001-120E346) fonuyla desteklenmiştir.

KAYNAKLAR

- [1] N. Aletras, D. Tsarapatsanis, D. Preoțiu-Pietro, and V. Lampos, "Predicting judicial decisions of the European Court of Human Rights: a Natural Language Processing perspective," *PeerJ Computer Science*, vol. 2, 2016.
- [2] A. Y. Ikram and L. Chakir, "Arabic text classification in the legal domain," in *2019 Third International Conference on Intelligent Computing in Data Sciences (ICDS)*. IEEE, 2019, pp. 1–6.
- [3] D. M. Katz, M. J. Bommarito, and J. Blackman, "A general approach for predicting the behavior of the supreme court of the United States," *PLoS one*, vol. 12, no. 4, p. e0174698, 2017.
- [4] K. Kowsrihawati, P. Vateekul, and P. Boonkwan, "Predicting judicial decisions of criminal cases from Thai Supreme Court using bi-directional GRU with attention mechanism," *2018 5th Asian Conference on Defense Technology (ACDT)*, pp. 50–55, 2018.
- [5] S. Long, C. Tu, Z. Liu, and M. Sun, "Automatic judgment prediction via legal reading comprehension," in *China National Conference on Chinese Computational Linguistics*. Springer, 2019, pp. 558–572.
- [6] B. G. Buchanan and T. E. Headrick, "Some speculation about artificial intelligence and legal reasoning," *Stanford Law Review*, vol. 23, pp. 40–62, 05 1970.
- [7] I. Chalkidis and D. Kampas, "Deep learning in law: early adaptation and legal word embeddings trained on large corpora," *Artificial Intelligence and Law*, vol. 27, no. 2, pp. 171–198, 2019.
- [8] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," in *1st International Conference on Learning Representations, ICLR 2013, Scottsdale, Arizona, USA, May 2-4, 2013, Workshop Track Proceedings*, Y. Bengio and Y. LeCun, Eds., 2013.
- [9] J. Pennington, R. Socher, and C. D. Manning, "Glove: Global vectors for word representation," in *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, 2014, pp. 1532–1543.
- [10] P. Bojanowski, E. Grave, A. Joulin, and T. Mikolov, "Enriching Word Vectors with Subword Information," *Transactions of the Association for Computational Linguistics*, vol. 5, pp. 135–146, 2017.
- [11] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. Minneapolis, Minnesota: Association for Computational Linguistics, Jun. 2019, pp. 4171–4186.
- [12] I. Chalkidis, M. Fergadiotis, P. Malakasiotis, N. Aletras, and I. Androutsopoulos, "LEGAL-BERT: The muppets straight out of law school," in *Findings of the Association for Computational Linguistics: EMNLP 2020*. Online: Association for Computational Linguistics, Nov. 2020.
- [13] N. Sevim, F. Şahinuç, and A. Koç, "Gender Bias in Legal Corpora and Debiasing It," *Natural Language Engineering*, 2022.
- [14] A. Köksal, "akoksal/turkish-word2vec," <https://github.com/akoksal/Turkish-Word2Vec>, 2021, date Accessed: 2021-01-31.
- [15] N. Sevim and A. Koç, "Investigation of Gender Bias in Turkish Word Embeddings," in *29th Signal Processing and Communications Applications Conference, SIU 2021, Istanbul, Turkey, June 9-11, 2021*. IEEE, 2021, pp. 1–4.
- [16] E. Mumcuoğlu, C. E. Öztürk, H. M. Ozaktas, and A. Koç, "Natural language processing in law: Prediction of outcomes in the higher courts of Turkey," *Information Processing & Management*, vol. 58, no. 5, p. 102684, 2021.
- [17] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Doha, Qatar: Association for Computational Linguistics, Oct. 2014, pp. 1724–1734.
- [18] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [19] S. Minaee, N. Kalchbrenner, E. Cambria, N. Nikzad, M. Chenaghlu, and J. Gao, "Deep learning-based text classification: A comprehensive review," *ACM Comput. Surv.*, vol. 54, no. 3, apr 2021.
- [20] I. Chalkidis, "Law2Vec: Legal Word Embeddings," <https://archive.org/details/Law2Vec>, 2013, date Accessed: 2021-05-17.
- [21] T. Fu, C. Zhang, and S. Mandt, "Continuous Word Embedding Fusion via Spectral Decomposition," in *Proceedings of the 22nd Conference on Computational Natural Language Learning*. Brussels, Belgium: Association for Computational Linguistics, Oct. 2018, pp. 11–20.
- [22] A. A. Akin and M. D. Akin, "Zemberek, an open source NLP framework for Turkic languages," <https://github.com/ahmetaa/zemberek-nlp>, 2013.
- [23] E. Tursun, D. Ganguly, T. Osman, Y.-T. Yang, G. Abdurkerim, J.-L. Zhou, and Q. Liu, "A semisupervised tag-transition-based Markovian model for Uyghur morphology analysis," *ACM Transactions on Asian and Low-Resource Language Information Processing*, vol. 16, no. 2, pp. 8:1–23, Nov. 2016.